PROYECTO INTEGRADOR 2

Grafos, Clustering y Aprendizaje de Representación sobre Contrataciones Públicas del Perú

Prof. Heider Sanchez

OBJETIVO

Este segundo proyecto integrador busca que cada equipo aplique, de manera articulada, las técnicas de clustering, sistemas de recomendación, análisis de enlaces, detección de comunidades y aprendizaje de representación en grafos, sobre los datos abiertos de contrataciones públicas del Perú (estándar OCDS). Se espera que el equipo plantee sus propias preguntas de interés y diseñe una estrategia técnica propia, **argumentando cada decisión metodológica para extraer conocimiento, no solo ejecutar algoritmos.**

Este enunciado plantea objetivos, mínimos exigibles y criterios de evaluación — no una receta paso a paso. No es obligatorio aplicar todas las variantes de cada familia de técnicas, pero cada familia debe quedar cubierta y analizada hasta obtener conclusiones. Una decisión bien justificada, aunque difiera del camino más obvio, suma. ***Para cada técnica, el equipo debe proponer qué patrón o pregunta busca responder y por qué es relevante.***

En un contexto donde las herramientas de IA facilitan generar código y texto, la evaluación pondrá especial énfasis en lo que realmente distingue a un buen trabajo: la profundidad del análisis, la interpretación de los resultados en el contexto peruano y la claridad con que se comunican. Entregar salidas o código sin comprenderlos ni saber explicarlos recibirá bajo puntaje, aunque "funcionen".

Dado que el proyecto se desarrolla en 5 semanas, prioricen la profundidad sobre la exhaustividad. Pueden reutilizar la base de datos ya limpia del primer proyecto: el mismo grano entidad–proveedor–ítem es justo lo que estas técnicas necesitan.

Al concluir el proyecto, el estudiante habrá:

- Transformado los datos, sobre Spark, en una base relacional: vectores de características, una matriz de interacción y un grafo (por co-participación o, de forma sencilla, un grafo KNN).
- Descubierto tipologías y anomalías mediante clustering (KMeans++, jerárquico, DBSCAN/HDBSCAN).
- Modelado la relación entidad–proveedor con sistemas de recomendación (vecindario, contenido y factores latentes).
- Identificado actores centrales con análisis de enlaces (PageRank y HITS).
- Segmentado el mercado con detección de comunidades (Girvan-Newman, modularidad, espectral, AGM/BigCLAM).
- Obtenido representaciones de nodos (SVD, Node2Vec o GNN) y las habrá usado en una tarea analítica.
- Analizado, interpretado y comunicado los hallazgos —mediante un reporte web interactivo— con encuadre ético.

CONTEXTO Y DATASET

Los datos abiertos de contrataciones públicas del Perú (OECE/OSCE, estándar OCDS) reúnen, para cada proceso, a la entidad compradora, los oferentes y proveedores, los ítems de bienes y servicios, los montos, las fechas y la ubicación. Esa estructura entidad–proveedor–ítem es intrínsecamente relacional, por lo que permite construir de forma natural los tres objetos que requiere este proyecto:

- Vectores de características por entidad o proveedor (para clustering).

- Una matriz de interacción entidad × proveedor o entidad × categoría (para recomendación y para SVD).
- Un grafo entre nodos: de co-participación (proveedores/entidades) o, de forma sencilla, un grafo KNN sobre los vectores (para enlaces, comunidades y representación).

Todos los equipos parten de este dataset (uso libre bajo licencia CC BY 4.0; debe citarse la fuente). Un equipo puede, en su lugar, proponer otro dataset de datos públicos siempre que permita aplicar todas las técnicas solicitadas: es decir, construir los tres objetos anteriores, teniendo presente que el grafo puede generarse directamente con un grafo KNN sobre los vectores cuando no exista una relación de co-participación evidente. En cualquier caso, cada equipo debe formular dos o tres preguntas de interés propias —no meramente descriptivas— y explicar su relevancia (concentración de mercado, segmentos de proveedores, actores centrales, patrones regionales, u otras).

Fuentes de datos

Fuente	Qué contiene / por qué sirve	Enlace
Registro OCDS – Perú (OECE/OSCE)	Dataset base del proyecto: procesos de contratación (entidades, proveedores, ítems, montos, fechas) en JSON/Excel/CSV, por año o histórico.	https://data.open-contracting.org/es/publication/135
Contrataciones Abiertas (OECE)	Portal con buscador, tableros y API sobre los mismos datos del SEACE en estándar OCDS.	https://contratacionesabiertas.oece.gob.pe/
Plataforma Nacional de Datos Abiertos	Catálogo central del Estado, por si un equipo desea enriquecer con otra fuente.	https://www.datosabiertos.gob.pe/
INEI – Sistema de Microdatos	Encuestas nacionales para cruces socioeconómicos o geográficos complementarios.	https://proyectos.inei.gob.pe/microdatos/
MEF – Transparencia Económica	Ejecución presupuestal, útil para contexto de gasto por entidad y jurisdicción.	https://www.mef.gob.pe/es/presentacion

Se debe citar explícitamente la fuente utilizada. Para descargas por año, el histórico completo supera los 1,9 GB comprimidos; se recomienda empezar por uno o pocos años representativos.

CONSIDERACIONES CLAVE DEL DATASET

- Resolución de entidades: la fuente advierte identificadores de proveedores duplicados; conviene deduplicar antes de construir los grafos (pueden reutilizar MinHash/LSH del Proyecto 1), o los nodos se fragmentarán.
- Enlaces incompletos: existen adjudicaciones sin contrato vinculado y viceversa; el equipo debe decidir y justificar cómo construye las aristas.
- Escalabilidad: con millones de nodos, algunos métodos (Girvan-Newman, clustering espectral exacto) solo son viables sobre un subgrafo representativo; variantes escalables (p. ej. GraphFrames, BigCLAM) permiten mayor tamaño. Comparar ambos es parte del análisis.
- Ética: los hallazgos sobre comunidades o enlaces pueden sugerir colusión; deben presentarse como señales descriptivas para posible revisión, nunca como acusaciones.

PARTE I. TRANSFORMACIÓN Y CONSTRUCCIÓN DE GRAFOS Y MATRICES CON SPARK

Uso de Spark: obligatorio en toda esta parte.

Objetivo: dejar lista, sobre Spark, la base relacional que alimentará a las demás partes.

- Aplanar y transformar los datos (OCDS en JSON o CSV relacional) al grano de análisis elegido. Se asume que la limpieza y el EDA ya fueron resueltos.
- Abordar la resolución de entidades de proveedores/compradores (identificadores duplicados).
- Construir y exportar los artefactos base: vectores de características, la matriz de interacción y el grafo —por co-participación o, cuando convenga, un grafo KNN sobre los vectores— documentando el criterio de aristas.
- Explicar el particionamiento y cómo afecta al plan de ejecución.

PARTE II. CLUSTERING Y DETECCIÓN DE ANOMALÍAS

Uso de Spark: opcional (Kmeans de Spark Mllib; densidad puede ir en local sobre una muestra).

Objetivo: descubrir tipologías de proveedores o entidades y outliers; el equipo define qué patrón busca.

- Definir y justificar las características, su estandarización y —de ser útil— una reducción de dimensión previa (PCA o SVD).
- Aplicar Kmeans++ con un criterio para elegir k (codo, silueta u otro) y al menos un método basado en densidad (DBSCAN o HDBSCAN); el jerárquico, al menos sobre una muestra, para obtener un dendrograma.
- *Interpretar los clústeres y los outliers*: qué perfil de comportamiento o gasto representan.

PARTE III. SISTEMAS DE RECOMENDACIÓN

Uso de Spark: opcional (ALS está disponible en Spark Mllib).

Objetivo: modelar la relación entidad–proveedor/categoría y analizar la estructura del mercado.

- Construir la matriz de interacción implícita (señal, p. ej., número de contratos o monto).
- Implementar al menos dos enfoques entre: filtrado colaborativo de vecindario (user-user / 3imp-item), basado en contenido (TF-IDF de descripciones o clasificación de ítems) y factores latentes (factorización de matrices / ALS).
- Para el filtrado por contenido a gran escala pueden usar búsqueda aproximada de vecinos (IVF o HNSW) sobre los vectores de ítems; se valora ensamblar filtrado colaborativo y por contenido en un recomendador híbrido.
- Evaluar (p. ej. Hold-out, métricas de ranking) e interpretar: proveedores sustitutos por categoría, afinidades inusuales. Mantener el encuadre analítico, no prescriptivo sobre a quién contratar.

PARTE IV. ANÁLISIS DE ENLACES: PAGERANK Y HITS

Uso de Spark: recomendado (GraphFrames escala PageRank; subgrafos en local para HITS).

Objetivo: identificar los actores más centrales de la red de contrataciones.

- Construir y justificar el grafo (definición de nodos y aristas).
- Calcular PageRank (Google matrix con teletransporte) e interpretar a los proveedores o entidades de mayor rango; analizar la sensibilidad al factor de amortiguamiento.
- Aplicar HITS sobre el bipartito e interpretar hubs (compradores) y authorities (proveedores).

PARTE V. GRAFOS Y DETECCIÓN DE COMUNIDADES

Uso de Spark: opcional (métodos exactos sobre subgrafo; variantes escalables sobre el grafo completo).

Objetivo: segmentar el mercado en comunidades y evaluar su calidad.

- Aplicar al menos un método de partición (Girvan-Newman / 4imp betweenness o clustering espectral) sobre un subgrafo manejable, evaluando con modularidad Q.
- Abordar comunidades solapadas con AGM o BigCLAM (al menos sobre un subgrafo), dado que un proveedor suele participar en varios mercados o consorcios.
- Discutir la escalabilidad: por qué los métodos exactos exigen submuestra y qué variantes permiten mayor escala.
- Interpretar las comunidades (mercados, regiones, agrupaciones a revisar), con encuadre ético.

PARTE VI. APRENDIZAJE DE REPRESENTACIÓN EN GRAFOS

Uso de Spark: opcional.

Objetivo: obtener representaciones vectoriales de los nodos y usarlas en una tarea analítica.

- Construir embeddings de nodos con al menos una técnica: SVD como embedder, Node2Vec o una GNN sobre el grafo (de co-participación o KNN).
- Usar los embeddings en una tarea concreta: clustering o visualización (t-SNE/UMAP) de nodos, o predicción de enlaces.
- Interpretar qué estructura capturan los embeddings y cómo se relacionan con los clústeres o comunidades hallados en las partes anteriores.

PARTE VII. ANÁLISIS, DISCUSIÓN Y COMUNICACIÓN

Objetivo: demostrar comprensión, no solo ejecución. Esta parte se evalúa con peso propio.

- ¿Qué técnicas aportaron más conocimiento para responder sus preguntas, y cuáles aportaron poco?
- ¿Convergen los resultados? Por ejemplo, ¿coinciden los clústeres, las comunidades del grafo y los grupos que emergen de los embeddings?
- ¿Qué métodos escalaron y cuáles exigieron submuestra? ¿Qué se gana y se pierde en cada caso?
- ¿Qué implicancias éticas tiene este análisis sobre compras públicas (señales vs. Acusaciones, transparencia, uso responsable)?
- ¿Cómo cambiarían las decisiones técnicas si el volumen o la cobertura fueran mucho mayores?

La comunicación cuenta: el reporte interactivo y la presentación deben priorizar la claridad y una narrativa que conecte los hallazgos con las preguntas planteadas.

REPORTE TÉCNICO INTERACTIVO (PÁGINA WEB)

Al igual que en el primer proyecto, el reporte técnico se entrega como una página web interactiva donde cada hallazgo pueda verse y explorarse. El texto de análisis (metodología, interpretación y discusión) va embebido en la propia página.

Estructura por hallazgo

Cada hallazgo se presenta como un módulo: pregunta de interés → visualización → controles interactivos (donde apliquen) → interpretación escrita.

Arquitectura recomendada: “calcular una vez, explorar muchas”

- Lo pesado (Spark, grafos, embeddings) se calcula offline y se exporta como artefactos ligeros (Parquet/CSV/JSON); la página los lee y responde al instante.
- La recomputación en vivo se reserva para lo barato: reasignar puntos a clústeres, filtrar comunidades, recalcular un ranking con otro parámetro.

Conviene dejar interactivos los parámetros clave: k en Kmeans; eps y min_samples en DBSCAN/HDBSCAN; número de factores o de recomendaciones; factor de amortiguamiento de PageRank; resolución o número de comunidades; y los parámetros p y q de Node2Vec.

Requisitos mínimos

- Al menos tres hallazgos con parámetros ajustables en vivo; el resto, como visualizaciones estáticas exportadas.
- Texto embebido de metodología, interpretación por hallazgo y discusión crítica.
- Enlace publicado o video corto de demostración, además del código.

Herramientas de libre elección (Streamlit, Voilà + ipywidgets, Panel, Dash/Plotly, Gradio, o HTML+JS con datos precalculados). Publicación opcional en Streamlit Community Cloud, Hugging Face Spaces, Binder o GitHub Pages.

CRONOGRAMA SUGERIDO (4 SEMANAS)

Referencial. Conviene cerrar la Parte I en la primera semana, pues construye la base que alimenta a todas las demás.

Semana	Enfoque	Entregable parcial sugerido
Semana 11	Parte I: transformación, resolución de entidades y construcción de la base relacional en Spark (features, matriz de interacción y grafo —co-participación o KNN). Partes II: clustering y detección de anomalías	Grafo y matriz de interacción exportados. Clústeres interpretados
Semana 12	Partes III: sistemas de recomendación sobre la matriz de interacción.	Recomendador evaluado.
Semana 13	Partes IV: análisis de enlaces (PageRank, HITS)	Ranking PageRank/HITS.
Semana 14	Parte V: detección de comunidades sobre el grafo	comunidades con modularidad
Semana 15	Parte VI (representación en grafos) y Parte VII (análisis y discusión). Reporte web interactivo y presentación.	Reporte web + presentación + código y registro de contribuciones.

Consejo: exporten los artefactos (grafo, matriz, embeddings, rankings) a medida que avanzan, en lugar de dejar el armado del reporte para la Semana 4.

ENTREGABLES ESPERADOS

1. Código fuente

- Implementaciones en Python con PySpark (y las librerías de grafos/ML que elijan), organizadas por bloque temático.
- Cada módulo debe indicar si la tarea se ejecuta en Spark o en local, y por qué.
- README con instrucciones, dependencias y el paso que exporta los artefactos para la web.

2. Reporte técnico interactivo (página web)

- Cada hallazgo como un módulo (pregunta, visualización, controles, interpretación), con metodología y discusión embebidas.
- Al menos tres hallazgos con parámetros ajustables en vivo; enlace publicado o video de demostración.

3. Presentación de resultados

- Exposición breve centrada en los hallazgos, su interpretación y una demostración de partes del código.

4. Registro de contribuciones

- Tabla que indique qué hizo cada integrante, acompañada de una traza verificable (historial de commits u otra evidencia). Es la base de la evaluación individual.

RÚBRICA DE EVALUACIÓN GRUPAL (20 PUNTOS)

Criterio	Descripción	Pts.
Transformación, construcción de grafos/matrices y Spark (Parte I)	Transformación, resolución de entidades y correcta construcción de la base relacional (features, matriz de interacción, grafo).	3
Clustering y detección de anomalías (Parte II)	Features y reducción de dimensión justificados, KMeans++ y un método de densidad, e interpretación de clústeres y outliers.	3
Sistemas de recomendación (Parte III)	Matriz de interacción, al menos dos enfoques (incluida opción híbrida o ANN para contenido), evaluación e interpretación.	3
Análisis de enlaces: PageRank y HITS (Parte IV)	Construcción justificada del grafo, PageRank y HITS, e interpretación de actores centrales.	2
Grafos y detección de comunidades (Parte V)	Partición y/o comunidades solapadas, evaluación con modularidad Q y discusión de escalabilidad.	2
Aprendizaje de representación (Parte VI)	Embeddings de nodos (SVD, Node2Vec o GNN) usados en una tarea analítica concreta e interpretados.	3
Análisis, discusión crítica (incl. ética) y reporte interactivo	Profundidad de la interpretación, integración de las técnicas, encuadre ético y calidad del reporte web y de la presentación.	3
Código y reproducibilidad	Organización, comentarios, README y facilidad para reproducir los resultados.	1
Total (nota grupal)		**20**

Bono opcional (hasta 1 punto adicional, fuera de los 20): originalidad en las preguntas de interés o en el enfoque técnico (por ejemplo, un recomendador híbrido robusto o el descubrimiento de un patrón no trivial), más allá de los mínimos exigidos.

EVALUACIÓN INDIVIDUAL

La nota de cada integrante no es automáticamente la del grupo. La nota grupal (sobre 20) se ajusta por un factor individual que refleja la contribución real y la capacidad de sustentar el trabajo:

Nota individual = Nota grupal × Factor individual (con un tope de 20).

Factor	Situación del integrante
1.0	Contribución equitativa y demostrable; sustenta con solvencia cualquier parte del proyecto.
0.7 – 0.9	Contribución parcial, o sustenta bien solo la parte en la que trabajó.
0.4 – 0.6	Contribución baja o poco evidente; dificultades para sustentar el trabajo.
0.0 – 0.3	Sin evidencia de contribución o no logra sustentar el trabajo.

El factor se determina a partir de: el registro de contribuciones y su traza (commits u otra evidencia), una sustentación oral individual en la que cualquier integrante pueda explicar cualquier parte del proyecto, y —opcionalmente— una coevaluación entre los miembros del equipo. Dos integrantes del mismo grupo pueden obtener notas distintas.

OBSERVACIONES

- Reutilizar la base limpia del Proyecto 1 (entidad–proveedor–ítem) es recomendable para ganar tiempo.
- Trabajar con un subconjunto representativo (por año, región o categoría) es válido y, para los métodos no escalables, necesario; debe justificarse.
- El uso de herramientas de IA es aceptable, pero cada integrante debe comprender y saber explicar lo que entrega; habrá sustentación individual.
- Se debe citar explícitamente la fuente de datos (OCDS – OECE/OSCE, CC BY 4.0).